

Detekce a rozpoznání registrační značky vozidla pro analýzu dopravy

Bc. Tereza Černá*



Abstrakt

Cílem této práce je detekce registračních značek vozidel a rozpoznání jejich textu. Základním přístupem pro detekci je využití kaskádového klasifikátoru. Práce je rozdělena do tří hlavních kapitol – získání datové sady, detekce značek a rozpoznání znaků. Datová sada byla pořízena na území města Brna přímo pro účely této práce a sloužila k trénování a vyhodnocení detektorů. Další dvě části pojednávají o přípravě pozitivních a negativních vzorků dat a jejich použití při trénování kaskádového klasifikátoru. Úspěšnost detekce registračních značek byla vyhodnocena na dvou datových sadách s výsledky 100% a 98.47%. Aktuálně se autorka zabývá rozpoznáním znaků a sestavením registrační značky.

Klíčová slova: Detekce registračních značek vozidel — Klasifikace znaků — Kaskádový klasifikátor — MSER

Přiložené materiály: Zdrojové kódy

*xcerna01@stud.fit.vutbr.cz, xcernatereza@gmail.com, Faculty of Information Technology, Brno University of Technology

1. Úvod

Detekce registrační značky vozidla a její rozpoznání je klíčovou technikou v mnoha aplikacích souvisejících s analýzou dopravy jako je odcitení vozidel, sledování silničního provozu, kontrola rychlosti vozidel aj.

Proces rozpoznání registračních značek se skládá ze dvou hlavních fází: 1) hledání registrační značky auta a 2) rozpoznání znaků značky. V obou fázích lze zvolit mnoho přístupů. Metody detekce registračních značek jsou postaveny na porovnávání výrezů původního obrazu se šablonami [1], detekci MSER regionů [2], detekci hran [3, 4] za použití vlnkové transformace [5] nebo fuzzy logiky [6, 7], kombinaci houghovy transformace a analýzy kontur [8]. Jiné metody jsou založeny na komponentách a konstruují podmíněná náhodná

pole [9] nebo extrahují příznaky SIFT [10].

Metody rozpoznání znaků jsou často založeny na extrakci znaků a jejich porovnání s předdefinovanými šablonami [4, 11]. Další metody jsou založeny na derivacích jádra [12], trénování SVM a jiných detektorů [13] nebo na neuronových sítích [7, 14, 15].

Tato práce pojednává o použití kaskádového klasifikátoru pro vytvoření detektoru registračních značek a detektorů znaků. Velká část práce se věnována přípravě dat pro kaskádový klasifikátor a jeho trénování. Úspěšnost detektoru registračních značek byla vyhodnocena na dvou datových sadách s výsledky 100% a 98.47%.

16

17

18

19

20

21

22

23

24

25

26

27

28

29 2. Kaskádový klasifikátor

30 Kaskádový klasifikátor slouží pro robustní a rychlou
31 detekci objektů v obraze. Tento přístup publikovali
32 Viola a Jones [16] na příkladu detekce obličeje, ale
33 lze jej použít i pro jiné objekty. Použití kaskádového
34 klasifikátoru poskytuje velkou snímkovou rychlos.

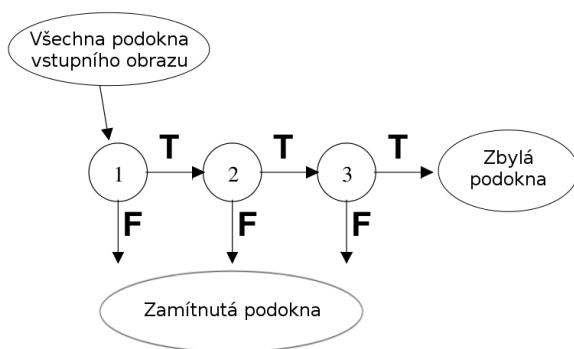
35 Je zde použita reprezentace obrazu zvaná integrální
36 obraz, která umožňuje velmi rychlé vyhodnocení funk-
37 ce. Systém detekce pracuje se sadou Haarových obdélníkových
38 příznaků (viz obr. 1).



Obrázek 1. Ukázka haarových příznaků

39 Klasifikátor je zkonstruován výběrem malého počtu
40 důležitých rysů algoritmu AdaBoost. V rámci zajištění
41 rychlé klasifikace musí proces učení vyloučit většinu
42 možných objektů a zaměřit se na malý soubor zásadních
43 rysů.

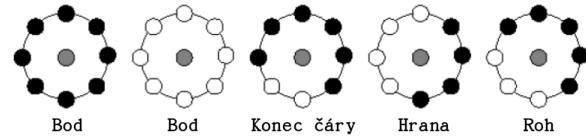
44 Celková podoba procesu detekce je konstrukce roz-
45 hodovacího stromu, který je nazýván kaskáda (viz obr.
46 2). Série klasifikátorů postupně zpracovává všechna
47 podokna vstupního obrazu. Iniciální klasifikátor elimi-
48 nuje velký počet negativních podoken s velmi krátkou
49 dobou zpracování. Následující klasifikátor odstraňuje
50 další negativní podokna, ale vyžaduje delší zpracování.
51 Po několika stupních kaskády je počet podoken radikál-
52 ně snížen. Kaskádou projdou pouze pozitivní podokna.



Obrázek 2. Schematický popis kaskádového klasifikátoru

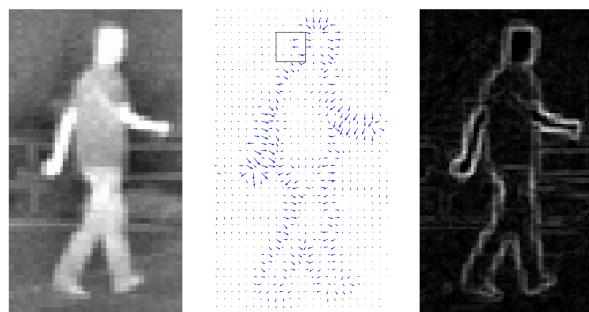
53 Kaskádový klasifikátor byl poprvé použit pro de-
54 tekci obličejů v obraze. Výsledný klasifikátor pracoval
55 s úspěšností 93.9 %.

56 Kaskádový klasifikátor umí pracovat nejen s Haaro-
57 vými příznaky, ale také s příznaky LBP, HOG a dalšími.
58 LBP příznaky neboli příznaky místních binárních vzorů
59 jsou získány pro všechny pixely v obraze. Pro každý
60 pixel je spočítán váhový součet okolních pixelů po
61 prahování. Příznaky jsou zobrazeny na obrázku 3.



Obrázek 3. Ukázka LBP příznaků

Cílem metody HOG podle pana Suarda a kol. [17] je popsat obraz souborem lokálních histogramů orientovaných gradientů. Nejprve dojde k vypočítání gradientů ve vstupním obrazu, poté je sestaven histogram orientace gradientů pro každý pixel a nakonec jsou všechny histogramy normalizovány v každém bloku pixelů. Na obrázku 4 je zobrazen výpočet HOG příznaků.



Obrázek 4. Ukázka HOG příznaků. Vlevo je originální obraz, uprostřed je ukázán směr gradientů, vpravo je zobrazena vizualizace získaných hodnot gradientů.

3. Datová sada

69 Pro dobrý výsledek detekčních úloh je zásadní pořídit
70 velkou datovou sadu. Čím větší datová sada, tím je
71 výsledný detektor robustnější. Datová sada použitá
72 v této práci byla získána v terénu na území města Brna.
73 Kamera byla umístěna:
74

- na úrovni aut s mírným úhlem k pruhu vozovky,
- nad úrovni aut (lávky, mosty) přímo proti pruhu vozovky a
- nad úrovni aut (lávky, mosty) s mírným úhlem k pruhu vozovky.

80 Bylo natočeno 25 použitelných videí, z nichž 23
81 bylo použito pro trénování detektoru a zbylá 2 videa
82 byla vyčleněna pro vyhodnocení úspěšnosti. Videa
83 byla natočena v délce od 30 s do 200 s. Průměrná
84 délka jednoho videa byla 1 min 50 s.

85 Jelikož by byla práce se všemi snímkami nasbíraných
86 videí zbytečná, tak z nich byl vyříznut každý 25 snímek,
87 který pak byl na vstupu učení detektoru. Ze získaných
88 snímků byly vymazány ty, na kterých se nevyskytovalo
89 žádné vozidlo. Tím došlo k omezení velmi shodných
90 snímků se stejnými informacemi.

91 **3.1 Data pro detekci registračních značek**

92 Na vstupu trénování detektoru registračních značek
93 byly snímky dopravy. Z těchto snímků byly vyříznuty
94 registrační značky, které byly vstupem trénování de-
95 tektoru. V následující tabulce jsou uvedeny počty pou-
žitých snímků:

Počet obrázků z dopravy	2811
Počet vyříznutých RZ	2745

96 **Tabulka 1.** Počty vstupních souborů

97 Způsob, jakým byla data použita pro trénování de-
98 tektoru registračních značek a jejich znaků je popsáno
99 v 4.1 a 5.1. Více o jejich použití při vyhodnocení
100 úspěšnosti je zmíněno v 4.3.

101 **4. Detekce registračních značek**

102 Pro detekci registračních značek byl zvolen kaskádový
103 klasifikátor knihovny OpenCV. Aby bylo možné detek-
104 tor natrénovat, bylo potřeba nachystat pozitivní a ne-
105 gativní data.

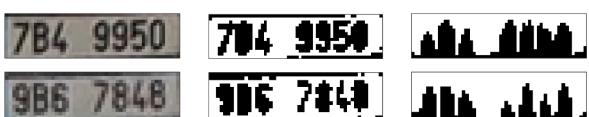
106 **4.1 Příprava dat pro trénink detektoru**

107 Kaskádový detektor vyžaduje pro trénování klasifiká-
108 toru velkou sadu obrázků pozitivních a negativních
109 případů a k nim odpovídající seznamy s cestami k ob-
110 rázkům. Pro přípravu dat vznikly v rámci této práce
111 dvě aplikace:

- 112 • training—find-LP,
- 113 • training—prepare-data.

114 **Nalezení poznávacích značek**

115 Aplikace **training—find-LP** je jednoduchým detekto-
116 rem registračních značek. Na vstupní snímek je apli-
117 kován detektor MSER regionů [18] a pro každý re-
118 gion je zkontrolována jeho velikost, poměr stran a úhel
119 sklonu vzhledem ke spodnímu okraji vstupního ob-
120 rázku. Tímto je mnoho regionů vyloučeno. Následně
121 je provedena analýza pixelů binárního výřezu regis-
122 trační značky, při které jsou sečteny počty pixelů ve
123 všech sloupcích (viz obrázek 5). V místech výskytu
124 písmen jdou vidět shluky černých pixelů. V ideálním
125 případě by měla analýza zobrazit 7 shluků. Jelikož
126 může být kvalita obrazu horší, pak je výřez prohlášen
127 za registrační značku, pokud obsahuje alespoň 3 tyto
128 shluky.



129 **Obrázek 5.** Ukázka analýzy pixelů

130 Výstupem této aplikace je adresář obsahující ob-
131 rázky nalezených registračních značek a seznam cest
132 k těmto souborům. Obrázky výřezů byly uloženy v po-
133 době name-x-y-w-h.png, kde *name* je jméno původního
134 snímku, proměnné *x* a *y* určují pozici levého horního
135 rohu značky v původním obraze a proměnné *w* a *h*
136 určují šířku a výšku výřezu.

137 Mezi získanými výřezy se nachází registrační znač-
138 ky vozidel, ale také obrázky s šumem. Pro odstranění
139 těchto milních značek je potřeba, aby uživatel ručně
140 prošel adresář s obrázky a smazal ty, které nepředstavují
141 registrační značky aut.

142 **Příprava pozitivní a negativní datové sady**

143 Druhá aplikace **training—prepare-data** připravuje
144 cíleně soubory pro trénování klasifikátoru. Aplikace
145 pracuje nad složkou registračních značek vygenero-
146 vanou předchozí aplikací. Pro všechny obrázky je vy-
147 tvořen adresář obsahující pozitivní vzorky, do něhož
148 jsou uloženy původní obrázky s celou scénou, a soubor
149 se seznamem pozitivních vzorků v podobě:
150 cesta-k-obrázku N x y šířka výška
151 x y šířka výška ...

152 Současně se vytvoří adresář pro negativní vzorky, do
153 něhož se ukládají opět obrázky s celou scénou, ale na-
154 detekované registrační značky jsou v nich začerněny.

155 Jelikož jednoduchým detektorem nebyly nadeteko-
156 vány všechny registrační značky, je opět nutný zásah
157 uživatele, který musí projít adresář s negativními snímký
158 a ručně začernit všechny zbývající viditelné značky,
159 které by úspěšnost klasifikátoru výrazně zhoršily.

160 **4.2 Trénování detektoru registračních značek**

161 Aplikace pro trénování klasifikátoru jsou v základu
162 knihovny OpenCV. Použity byly dvě základní funkce
163 **opencv_createsamples** a **opencv_traincascade** [19].

164 Pro trénování byly použity obrázky dopravy poříze-
165 né na území města Brna, v nichž je registrační značka
166 rovnoběžná se spodní hranou obrázku, případně s mír-
167 ným sklonem. Na vstupu trénování obsahovala poziti-
168 vní sada 2745 výřezů registračních značek. Negativní
169 sada byla vytvořena výřezy z 236 obrázků dopravy
170 v nichž byly registrační značky aut začerněny.

171 První funkce **opencv_createsamples** vytvořila po-
172 zitivní vzorky z jednoho obrázku či kolekce obrázků.
173 Funkce byla spuštěna s následujícími parametry:

```
174 ./opencv_createsamples  
175 -info /$PATH/pos-list.dat  
176 -vec /$PATH/samples.vec  
177 -w 60 -h 16 -num 2745
```

178 Samotné trénování kaskády proběhlo spuštěním
179 funkce **opencv_traincascade**. Trénování proběhlo v de-
180 seti iteracích, do každé iterace šlo 1000 pozitivních

```

180 a 1000 negativních vzorků. Pro trénování byly použity
181 příznaky LBP. Použitý příkaz pro spuštění:
182     ./opencv_traincascade
183         -data /$PATH/classifier
184         -vec /$PATH/samples.vec
185         -bg /$PATH/neg-list.dat
186         -numPos 1000 -numNeg 1000
187         -numStages 10 -w 60 -h 16
188         -featureType LBP

```

Výsledný detektor byl natrénován na minimální vektorost registrační značky, ve které zůstanou informace o jejích znacích, a to 60×16 pixelů.

4.3 Aplikace vyhodnocení detektoru

Pro vyhodnocení úspěšnosti bylo nejprve potřeba vytvořit soubor s anotacemi, kde se vyskytují registrační značky ve snímcích z dopravy. Pro tento účel vznikla aplikace **create-annotation**. Postupně se ukazují obrázky, ve kterých uživatel označí levý horní roh a pravý dolní roh textu na značce. Získané informace se vypisují na standardní výstup terminálu, které lze přesměrovat do souboru. Výstup aplikace je v podobě:

cesta-k-obrázku N x1 y1 x2 x2 ... ,
kde N je počet RZ v obrázku, x1 a y1 udávají souřadnice levého horního rohu znaků v RZ a x2 a y2 udávají souřadnice pravého dolního rohu.

Samotné vyhodnocení úspěšnosti provádí aplikace **automatic-evaluation**. Jejím vstupem je soubor s anotacemi a natrénovaný detektor. Aplikace porovnává, zda anotace registrační značky odpovídá některému výřezu nalezenému detektorem. V průběhu zpracování se počítá celkové množství registračních značek v anotovaném souboru a počet správně nadetekovaných značek. Tyto hodnoty jsou vypsány na standardní výstup terminálů společně s procentuálním vyjádřením úspěšnosti.

5. Klasifikace znaků registrační značky

5.1 Extrakce znaků z registračních značek

Před začátkem trénování detektorů znaků bylo třeba opět zajistit pozitivní a negativní sadu znaků. Pro tento účel vznikla aplikace extract-letters.

Vstupem této aplikace je adresář obsahující obrázky s vyříznutými registračními značkami. Značky jsou postupně ukazovány uživateli, který napíše na klávesnici znaky z registrační značky. Uživatel dále nakliká myší středy znaků. Aplikace poté vyřízne jednotlivé znaky a uloží je do obrázků náležejícím danému znaku. Vznikají tak sady pozitivních vzorků všech znaků (viz obrázek 6). Současně vzniká i negativní datová sada. V aktuální zobrazené registrační značce dojde k začernění daného znaku, např. A. Tato značka je poté

uložena do negativní sady náležející znaku A. Pokud se ve značce některý ze znaků nevyskytuje, pak je do jeho negativní sady uložena celá značka beze změny. Ukázka negativní sady znaku 1 je vidět na obrázku 7.



Obrázek 6. Ukázka vyextrahovaných znaků.



Obrázek 7. Ukázka negativní sady znaku 1.

5.2 Třídění znaků dle kvality

Kvalita některých znaků je velmi malá, proto byla vytvořena aplikace **sort-to-categories**, která roztrídí znaky z obrázku 6 do tří kategorií: dobré, střední a špatné. Rozdíl mezi kategoriemi je zobrazen na obrázku 8. Pro trénování byly použity znaky z kategorie dobré. Zbylé dvě kategorie jsou nachystané pro experimenty.



Obrázek 8. Ukázka roztríděných znaků dle kvality. Vlevo kategorie "dobré", vpravo kategorie "špatné".

5.3 Trénování detektorů znaků

Při trénování detektorů znaků probíhaly experimenty s použitím kaskádového klasifikátoru. Byly natrénovány detektory pro znaky 0, 1, 5, 6, 7, 8 a 9 za použití HOG příznaků. V rámci experimentování s výsledky detektorů bylo zjištěno, že hodnoty výstupních proměnných `rejectLevels` a `foundWeights` nejsou uspokojivé a od použití kaskádového klasifikátoru bylo tedy upuštěno.

Nyní probíhají experimenty s knihovnou LIBLINEAR [20] a trénováním SVM detektoru znaků.

6. Experimentální výsledky

6.1 Výsledky detektoru registračních značek

Výstup detektoru obsahuje většinu registračních značek, ale také spoustu chybějících výřezů (FP - false positives). FP není třeba řešit, protože na získané výřezy

257 vstupního snímku bude puštěn klasifikátor znaků a ten
258 tyto výřezy zamítne.

259 Výsledky detektoru jsou zobrazeny v tabulce 2.
260 Úspěšnost závisí na kvalitě vstupní datové sady. Vy-
261 hodnocení proběhlo na setu obrázků, ve kterých byly
262 registrační značky čitelné. Výsledný detektor umí čás-
263 tečně najít registrační značky, které jsou z části skryté
264 za jiným autem, ale tyto částečné detekce nebyly hod-
265 noceny.

	Dataset A	Dataset B
Počet snímků	75	103
Počet RZ	96	131
Počet nalezených RZ	96	129
Počet nenalezených RZ	0	2
Úspěšnost	100%	98.47%

Tabulka 2. Výsledky detektoru registračních značek

266 Na obrázku 9 jsou zobrazeny výstupy detekce re-
267 gistračních značek. V zelených rámečkách jsou zob-
268 razeny plochy, které detektor považuje za registrační
269 značky.

270 7. Závěr

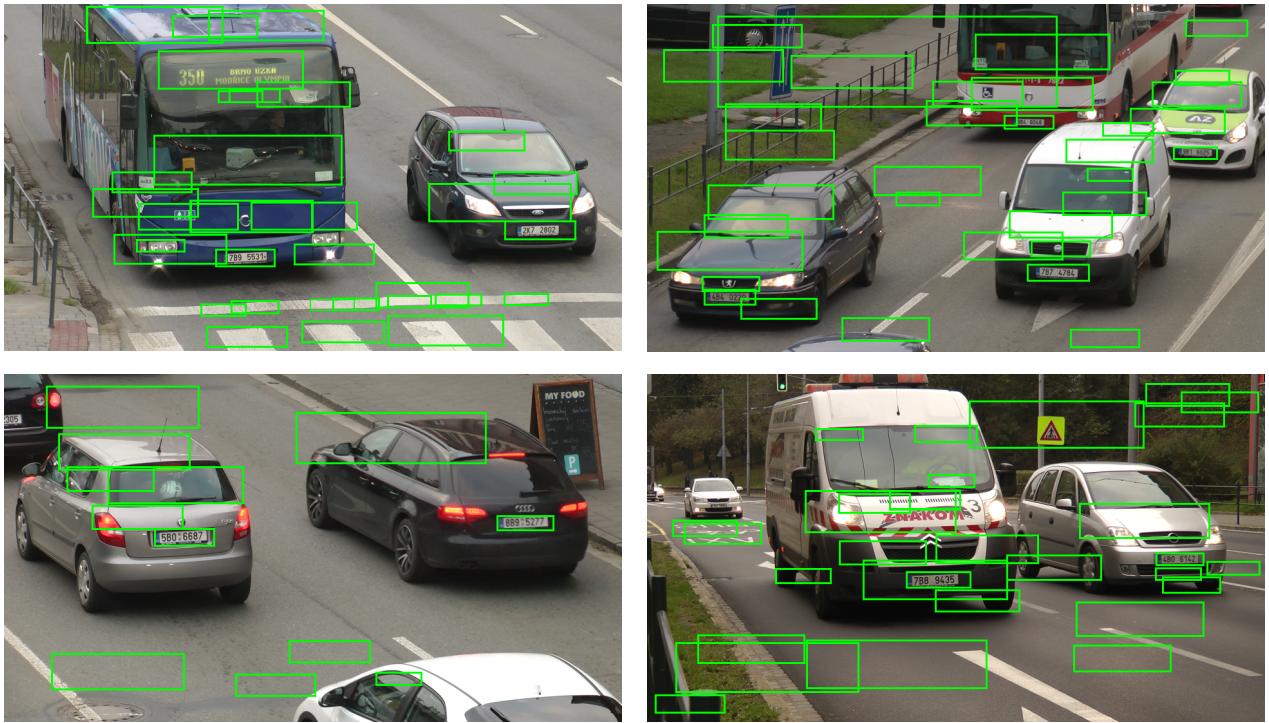
271 Cílem této práce bylo detektovat registrační značky ve
272 vstupním obraze ze silniční dopravy a následně kla-
273 sifikovat znaky a sestavit podobu registrační značky.
274 V kapitole 2 byl představen kaskádový klasifikátor. Ka-
275 pitola 3 se zabývala pořízením datové sady. Následující
276 kapitola hovořila o přípravě dat a trénování detektoru
277 registračních značek. Kapitola 5 pojednává o extrakci
278 znaků pro trénování klasifikátoru znaků a experimen-
279 tech s kaskádovým klasifikátorem. Předposlední kapi-
280 tola shrnuje dosažené výsledky.

281 Hlavním přístupem této práce bylo využití kaská-
282 dového klasifikátoru. Jeho použitím pro detekci regis-
283 tračních značek vznikl detektor, který dosahoval úspěš-
284 nosti 100% a 98.47% na dvou testovacích datových
285 sadách.

286 Budoucí činnost bude zaměřena na sestavení regis-
287 trační značky na základě výsledků SVM klasifikátoru
288 a její vyhodnocení. Dále bude vytvořena aplikace,
289 která spojí detekci registračních značek a rozpoznání
290 znaků. Na závěr proběhne vyhodnocení úspěšnosti
291 celé aplikace.

292 Literatura

- [1] Amir Hossein Ashtari, Mohd Jan Nordin, and Seyed Mostafa Mousavi Kahaki. A new reliable approach for persian license plate detection on colour images. In *ICEEI*, pages 1–5. IEEE, 2011.
- [2] Wei Wang, Qiaojing Jiang, Xi Zhou, and Wenyin Wan. Car license plate detection based on MSER. In *Consumer Electronics, Communications and Networks (CECNet), 2011 International Conference on*, pages 3973–3976, April 2011.
- [3] Z. Musoromy, S. Ramalingam, and N. Bekooy. Edge detection comparison for license plate detection. In *Control Automation Robotics Vision (ICARCV), 2010 11th International Conference on*, pages 1133–1138, Dec 2010.
- [4] Wai-Yiu Ho and Chi-Man Pun. A Macao license plate recognition system based on edge and projection analysis. In *IEEE International Conference on Industrial Informatics*, 2010.
- [5] Z. Musoromy, F. Bensaali, S. Ramalingam, and G. Pissanidis. Comparison of real-time dsp-based edge detection techniques for license plate detection. In *Information Assurance and Security (IAS), 2010 Sixth International Conference on*, pages 323–328, Aug 2010.
- [6] Shyang-Lih Chang, Li-Shien Chen, Yun-Chung Chung, and Sei-Wan Chen. Automatic license plate recognition. *Intelligent Transportation Systems, IEEE Transactions on*, 5(1):42–53, March 2004.
- [7] J.A.G. Nijhuis, M.H. ter Brugge, K.A. Helmholt, J.P.W. Pluim, L. Spaanenburg, R.S. Venema, and M.A. Westenberg. Car license plate recognition with neural networks and fuzzy logic. In *Neural Networks, 1995. Proceedings., IEEE International Conference on*, volume 5, pages 2232–2236 vol.5, Nov 1995.
- [8] Tran Duc Duan, Duong Anh Duc, and Tran Le Hong Du. Combining hough transform and contour algorithm for detecting vehicles licence plates. In *International Symposium on Intelligent Multimedia, Video and Speech Processing*, pages 747–750, 2004.
- [9] Bo Li, Bin Tian, Ye Li, and Ding Wen. Component-based license plate detection using conditional random field model. *IEEE Transactions on Intelligent Transportation Systems*, 14(4):1690–1699, 2013.
- [10] Wengang Zhou, Houqiang Li, Yijuan Lu, and Qi Tian. Principal visual word discovery for automatic license plate detection. *IEEE Transactions on Image Processing*, 21(9):4269–4279, 2012.
- [11] P. Cika, M. Zukal, and M. Sebela. Detection and recognition of license plates of czech vehicles. In *ElektroRevue*, volume 2, December 2011.



Obrázek 9. Ukázka výstupu detektoru registračních značek.

- [12] Zhen Chao Zhang and Yuan Yan Tang. License plate recognition algorithm based on derived kernel. In *Wavelet Analysis and Pattern Recognition (ICWAPR), 2012 International Conference on*, pages 238–243, July 2012.
- [13] L. Neumann. Vyhledání a rozpoznání textu v obrazech reálných scén, diplomová práce, Praha, ČVUT, 2010 [cit. 2015-03-29].
- [14] Lorita Angeline, Wei Leong Khong, Farrah Wong, Ismail Saad, and Kenneth Tze Kin Teo. Multiple vehicles license plate tracking and recognition via isotropic dilation. In *CICSyN*, pages 54–59. IEEE, 2011.
- [15] Sneha G. Patel. Vehicle licence plate recognition using morphology and neural network. In *International Journal on Cybernetics & Informatics*, 2013.
- [16] Paul Viola and Michael Jones. Rapid object detection using a boosted cascade of simple features. In *Accepted Conference on Computer Vision and Pattern Recognition*, pages 511–518, 2001.
- [17] F. Suard, A. Rakotomamonjy, A. Bensrhair, and Alberto Broggi. Pedestrian Detection using Infrared images and Histograms of Oriented Gradients. In *Procs. IEEE Intelligent Vehicles Symposium 2006*, pages 206–212, Tokyo, Japan, June 2006.
- [18] J. Matas, O. Chum, M. Urban, and T. Pajdla. Robust wide baseline stereo from maximally stable extremal regions. In *In British Machine Vision Conference*, pages 384–393, 2002.
- [19] Cascade classifier training. http://docs.opencv.org/doc/user_guide/ug_traincascade.html. [cit. 2015-03-16].
- [20] Rong-En Fan, Kai-Wei Chang, Cho-Jui Hsieh, Xiang-Rui Wang, and Chih-Jen Lin. LIBLINEAR: A library for large linear classification. *Journal of Machine Learning Research*, 9:1871–1874, 2008.