

# Detekce a rozpoznání registrační značky vozidla pro analýzu dopravy

Bc. Tereza Černá\*



## Abstrakt

Cílem této práce je detekce registračních značek vozidel. Základním přístupem pro detekci je využití kaskádového klasifikátoru. Práce je rozdělena do tří hlavních kapitol – popis datové sady, detekce značek a diskuze výsledků. Datová sada byla pořízena na území města Brna přímo pro účely této práce. Nasbíraná data byla použita pro přípravu pozitivních a negativních vzorků pro trénování detektoru registračních značek a klasifikátoru znaků. V práci je popsáno trénování kaskádového klasifikátoru pro detekci registračních značek. Úspěšnost detekce značek byla vyhodnocena na dvou datových sadách s výsledky 100 % a 98.47 %. Aktuálně se autorka zabývá rozpoznáním znaků a sestavením registrační značky.

**Klíčová slova:** Detekce registračních značek vozidel — Klasifikace znaků — Kaskádový klasifikátor — MSER

**Přiložené materiály:** Zdrojové kódy

\*[xcerna01@stud.fit.vutbr.cz](mailto:xcerna01@stud.fit.vutbr.cz), [xcernatereza@gmail.com](mailto:xcernatereza@gmail.com), Faculty of Information Technology, Brno University of Technology

## 1. Úvod

Detekce registrační značky vozidla a její rozpoznání je klíčovou technikou v mnoha aplikacích souvisejících s analýzou dopravy jako je odcizení vozidel, sledování silničního provozu, kontrola rychlosti vozidel aj.

Proces rozpoznání registračních značek se skládá ze dvou hlavních fází: 1) hledání registrační značky auta a 2) rozpoznání znaků značky. V obou fázích lze zvolit mnoho přístupů. Metody detekce registračních značek jsou postaveny na porovnávání výřezů původního obrazu se šablonami [1], detekci MSER regionů [2], detekci hran [3] za použití vlnkové transformace [4] nebo fuzzy logiky [5], kombinaci houghovy transformace a analýzy kontur [6]. Jiné metody jsou založeny na komponentách a konstruují podmíněná náhodná pole [7] nebo extrahují příznaky SIFT [8].

Metody rozpoznání znaků jsou často založeny na extrakci znaků a jejich porovnání s předdefinovanými šablonami [9]. Další metody jsou založeny na derivacích jádra [10], trénování SVM a jiných detektorů [11] nebo na neuronových sítích [12].

Tato práce pojednává o použití kaskádového klasifikátoru pro vytvoření detektoru registračních značek. Velká část práce se věnována přípravě dat pro trénování detektoru registračních značek a klasifikátoru znaků. Úspěšnost detektoru registračních značek byla vyhodnocena na dvou datových sadách s výsledky 100 % a 98.47 %.

17  
18  
19  
20  
21  
22  
23  
24  
25  
26  
27  
28

## 29 2. Kaskádový klasifikátor

30 Kaskádový klasifikátor slouží pro robustní a rychlou  
31 detekci objektů v obraze. Tento přístup publikovali  
32 Viola a Jones [13] na příkladu detekce obličeje, ale  
33 lze jej použít i pro jiné objekty. Použití kaskádového  
34 klasifikátoru poskytuje velkou snímkovou rychlos.

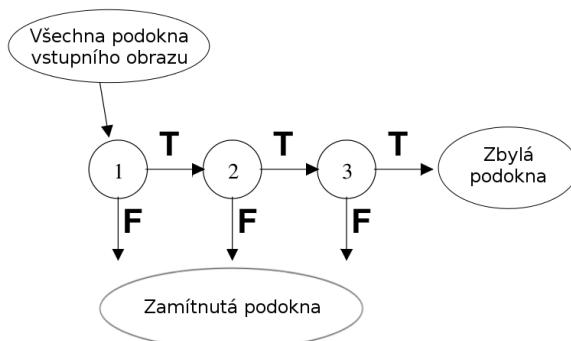
35 Je zde použita reprezentace obrazu zvaná integrální  
36 obraz, která umožňuje velmi rychlé vyhodnocení funk-  
37 ce. Systém detekce pracuje se sadou Haarových obdélníkových  
38 příznaků (viz obr. 1).



Obrázek 1. Ukázka haarových příznaků

39 Klasifikátor je zkonstruován výběrem malého počtu  
40 důležitých rysů algoritmu AdaBoost. V rámci zajištění  
41 rychlé klasifikace musí proces učení vyloučit většinu  
42 možných objektů a zaměřit se na malý soubor zásadních  
43 rysů.

44 Celková podoba procesu detekce je konstrukce roz-  
45 hodovacího stromu, který je nazýván kaskáda (viz obr.  
46 2). Série klasifikátorů postupně zpracovává všechna  
47 podokna vstupního obrazu. Iniciální klasifikátor elimi-  
48 nuje velký počet negativních podoken s velmi krátkou  
49 dobou zpracování. Následující klasifikátor odstraňuje  
50 další negativní podokna, ale vyžaduje delší zpracování.  
51 Po několika stupních kaskády je počet podoken radikál-  
52 ně snížen. Kaskádou projdou pouze pozitivní podokna.

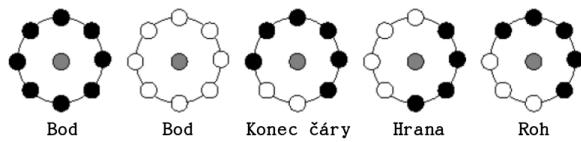


Obrázek 2. Schematický popis kaskádového klasifikátoru

53 Kaskádový klasifikátor byl poprvé použit pro de-  
54 tekci obličejů v obraze. Výsledný klasifikátor pracoval  
55 s úspěšností 93.9 %.

56 Tento klasifikátor umí pracovat nejen s Haarovými  
57 příznaky, ale také s příznaky LBP, HOG a dalšími. LBP  
58 příznaky neboli příznaky místních binárních vzorů jsou  
59 získány pro všechny pixely v obraze. Pro každý pixel je  
60 spočítán váhový součet okolních pixelů po prahování.  
61 Příznaky jsou zobrazeny na obrázku 3. LBP příznaky

byly použity v této práci pro vytvoření detektoru regis-  
62 tračních značek. 63



Obrázek 3. Ukázka LBP příznaků

## 3. Datová sada

### 3.1 Pořízení datové sady

64 Pro dobrý výsledek detekčních úloh je zásadní pořídit  
65 velkou datovou sadu. Čím větší datová sada, tím je  
66 výsledný detektor robustnější. Datová sada použitá  
67 v této práci byla získána v terénu na území města Brna.  
68 Kamera byla umístěna:  
69

- 70 • na úrovni aut s mírným úhlem k pruhu vozovky,  
71 • nad úrovni aut (lávky, mosty) přímo proti pruhu  
72 vozovky a  
73 • nad úrovni aut (lávky, mosty) s mírným úhlem  
74 k pruhu vozovky.  
75

76 Bylo natočeno 25 použitelných videí, z nichž 23  
77 bylo použito pro trénování detektoru a zbylé 2 videa  
78 byla vyčleněna pro vyhodnocení úspěšnosti. Videa  
79 byla natočena v délce od 30 s do 200 s. Průměrná  
80 délka jednoho videa byla 1 min 50 s.

81 Jelikož by byla práce se všemi snímky nasbíraných  
82 videí zbytečná, tak z nich byl vyříznut každý 25 snímek,  
83 který pak byl na vstupu učení detektoru. Ze získaných  
84 snímků byla vymazána ty, na kterých se nevyskytovalo  
85 žádné vozidlo. Tím došlo k omezení velmi shodných  
86 snímků se stejnými informacemi.

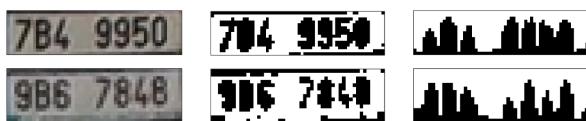
### 3.2 Datová sada pro detekci registračních značek

87 Pro vytvoření detektoru registračních značek byl zvo-  
88 len kaskádový klasifikátor knihovny OpenCV. Tento  
89 detektor vyžaduje pro trénování klasifikátoru velkou  
90 sadu obrázků pozitivních a negativních případů a k nim  
91 odpovídající seznamy s cestami k obrázkům. Pro pří-  
92 pravu dat vznikly v rámci této práce dvě aplikace:  
93

- 94 • **training—find-LP** – jednoduchý detektor re-  
95 gistračních značek využívající detekci MSER  
96 regionů,  
97 • **training—prepare-data** – příprava datových  
98 souborů pozitivní a negativní datové sady.  
99

100 Jednoduchý detektor je založen na detekci MSER  
101 regionů [14] ve vstupním snímku. Pro každý region  
102 je zkontovalo jeho velikost, poměr stran a úhel

103 sklonu vzhledem ke spodnímu okraji snímku, čímž  
104 dojde k omezení množství regionů. Nad zbylými re-  
105 giony je provedena binární analýza pixelů, při které  
106 jsou sečteny počty černých pixelů ve všech sloupcích  
107 (viz obrázek 4). V místech výskytu písmen jdou vidět  
108 shluky černých pixelů. V ideálním případě by měla  
109 analýza zobrazit 7 shluků. Jelikož může být kvalita  
110 obrazu horší, pak je výřez prohlášen za registrační  
111 značku, pokud obsahuje alespoň 3 tyto shluky.



Obrázek 4. Ukázka analýzy pixelů

112 Mezi získanými výřezy se nachází registrační znač-  
113 ky vozidel, ale také obrázky se šumem. Pro odstranění  
114 těchto mylných značek je potřeba, aby uživatel ručně  
115 prošel adresář s obrázky a smazal ty, které nepředstavují  
116 registrační značky aut.

117 Následně jsou již připraveny textové soubory pro  
118 trénování klasifikátoru. Je vytvořen adresář obsahující  
119 pozitivní vzorky, do něhož jsou uloženy původní obrázky  
120 z dopravy, a soubor se seznamem pozitivních vzorků v  
121 podobě:  
122 cesta-k-obrázku N x y šířka výška  
123 x y šířka výška ...  
124 kde proměnné x, y, šířka a výška určují přesnou pozici  
125 registrační značky v obraze.

126 Současně je vytvořen soubor se seznamem cest  
127 k negativním vzorkům a adresář, do něhož jsou uloženy  
128 obrázky s celou scénou, v nichž jsou na nalezené re-  
129 gistrační značky začerněny. Zde je opět nutný zásah  
130 uživatele, který musí projít adresář s negativními snímkami  
131 a začernit zbývající viditelné značky, které by úspěšnost  
132 klasifikátoru výrazně zhoršily.

### 133 3.3 Datová sada pro rozpoznání znaků

134 Před začátkem trénování detektorů znaků bylo třeba  
135 opět zajistit pozitivní a negativní sadu znaků. Pro tento  
136 účel vznikla aplikace **extract-letters**.

137 Vstupem této aplikace je adresář obsahující obráz-  
138 ky s vyříznutými registračními značkami. Značky jsou  
139 postupně ukazovány uživateli, který napíše na kláves-  
140 nici znaky z registrační značky. Uživatel dále nakliká  
141 myší středy znaků. Aplikace poté vyřízne jednotlivé  
142 znaky a uloží je do obrázků náležejícím danému znaku.  
143 Vznikají tak sady pozitivních vzorků všech znaků  
144 (viz obrázek 5). Současně vzniká i negativní datová  
145 sada. V aktuální zobrazené registrační značce dojde  
146 k začernění daného znaku, např. A. Tato značka je poté  
147 uložena do negativní sady náležející znaku A. Pokud  
148 se ve značce některý ze znaků nevyskytuje, pak je do

jeho negativní sady uložena celá značka beze změny. 149  
Ukázka negativní sady znaku 1 je vidět na obrázku 6. 150



Obrázek 5. Ukázka vyextrahovaných znaků.



Obrázek 6. Ukázka negativní sady znaku 1.

Kvalita některých znaků je velmi malá, proto byla 151  
vytvořena aplikace **sort-to-categories**, která roztrídí 152  
značky z obrázku 5 do tří kategorií: dobré, střední a špat- 153  
né. Rozdíl mezi kategoriemi je zobrazen na obrázku 154  
7. Pro trénování budou použity nejdříve znaky z ka- 155  
tegorie dobré. Zbylé kategorie jsou nachystány pro 156  
experimenty. 157



Obrázek 7. Ukázka roztríděných znaků dle kvality.  
Vlevo kategorie "dobré", vpravo kategorie "špatné".

V tabulce 1 jsou zobrazeny počty vyextrahovaných 158  
značek z registračních značek testovací datové sady. Na 159  
území města Brna se nepodařilo nasbírat dostatečný 160  
počet všech písmen abecedy. Pro tato písmena nebude 161  
možné natrénovat kvalitní klasifikátor, a proto nejsou 162  
ani uvedena v tabulce. 163

Znak	Počty znaků			
	celkem	dobré	střední	špatné
0	969	441	365	163
1	1158	680	383	95
2	1154	536	266	352
3	1184	573	289	322
4	1300	642	317	341
5	1209	705	175	329
6	1095	483	314	298
7	1352	580	358	414
8	1111	489	275	347
9	1235	783	118	334
A	256	124	49	83
B	1531	683	409	439

Tabulka 1. Počty vyextrahovaných znaků

## 164 4. Detekce registračních značek

### 165 4.1 Trénování detektoru registračních značek

166 Pro detekci registračních značek byl zvolen kaskádový  
167 klasifikátor knihovny OpenCV. Použity byly dvě zá-  
168 kladní funkce `opencv_createsamples` a `opencv_train-  
169 cascade` [15].

170 Pro trénování byly použity obrázky dopravy, v nichž  
171 je registrační značka rovnoběžná se spodní hranou  
172 obrázku, případně s mírným sklonem. V tabulce 2  
173 jsou uvedeny počty použitých snímků. Na začátku  
174 trénování byly obrázky negativní datové sady rozsekány  
175 na menší podokna, která se použila pro samotné tréno-  
176 vání. Pro trénování byla použita datová sada popsaná  
177 v kapitole 3.2.

Počet snímků pozitivní sady	2745
Počet snímků negativní sady	236

Tabulka 2. Počty vstupních souborů

178 První funkce `opencv_createsamples` vytvořila po-  
179 zitivní vzorky z jednoho obrázku či kolekce obrázků.  
180 Funkce byla spuštěna s následujícími parametry:

```
181 ./opencv_createsamples  
182     -info /$PATH/pos-list.dat  
183     -vec /$PATH/samples.vec  
184     -w 60 -h 16 -num 2745
```

185 Samotné trénování kaskády proběhlo spuštěním  
186 funkce `opencv_traincascade`. Trénování proběhlo v de-  
187 seti iteracích, do každé iterace šlo 1000 pozitivních  
188 a 1000 negativních vzorků. Pro trénování byly použity  
189 příznaky LBP. Použitý příkaz pro spuštění:

```
190 ./opencv_traincascade  
191     -data /$PATH/classifier  
192     -vec /$PATH/samples.vec  
193     -bg /$PATH/neg-list.dat  
194     -numPos 1000 -numNeg 1000  
195     -numStages 10 -w 60 -h 16  
196     -featureType LBP
```

197 Výsledný detektor byl natrenován na minimální ve-  
198 likost registrační značky, ve které zůstanou informace  
199 o jejích znacích, a to  $60 \times 16$  pixelů.

### 200 4.2 Aplikace vyhodnocení detektoru

201 Pro vyhodnocení úspěšnosti bylo nejprve potřeba vyt-  
202 vořit soubor s anotacemi, kde se vyskytují registrační  
203 značky ve snímcích z dopravy. Pro tento účel vznikla  
204 aplikace `create-annotation`. Postupně se ukazují ob-  
205 rázky, ve kterých uživatel označí levý horní roh a pravý  
206 dolní roh textu na značce. Získané informace se vypi-  
207 sují na standardní výstup terminálu, které lze přesmě-  
208 rovat do souboru. Výstup aplikace je v podobě:

cesta-k-obrázku N x1 y1 x2 x2 ... , 209  
kde N je počet RZ v obrázku, x1 a y1 udávají souřadnice 210  
levého horního rohu znaků v RZ a x2 a y2 udávají 211  
souřadnice pravého dolního rohu. 212

Samotné vyhodnocení úspěšnosti provádí aplikace 213  
**automatic-evaluation**. Jejím vstupem je soubor s anotacemi 214  
a natrenovaný detektor. Aplikace porovnává, 215  
zda anotace registrační značky odpovídá některému 216  
výřezu nalezenému detektorem. V průběhu zpracování 217  
se počítá celkové množství registračních značek v anotovaném 218  
souboru a počet správně nadetekovaných značek. Tyto 219  
hodnoty jsou vypsány na standardní výstup 220  
terminálů společně s procentuálním vyjádřením úspěšnosti. 221

## 223 5. Výsledky detektoru registračních značek

Výstup detektoru obsahuje většinu registračních značek, 224  
ale také spoustu chybě nalezených výřezů (FP - false 225  
positives). FP není třeba řešit, protože na získané výřezy 226  
vstupního snímku bude puštěn klasifikátor znaků a ten 227  
tyto výřezy zamítne. 228

Vyhodnocení úspěšnosti detektoru probíhalo na 229  
dvou datových sadách, které byly pořízeny na různých 230  
místech a jejichž registrační značky byly čitelné. Da- 231  
tové sady se lišily i v dalších faktorech: 232

- Dataset A – kamera snímalá zadní část aut z nad- 233  
hledu pod úhlem  $50^\circ$  k vozovce, 234
- Dataset B – kamera snímalá přední část aut, byla 235  
umístěna na jejich úrovni pod úhlem  $65^\circ$  k vo- 236  
zovce. 237

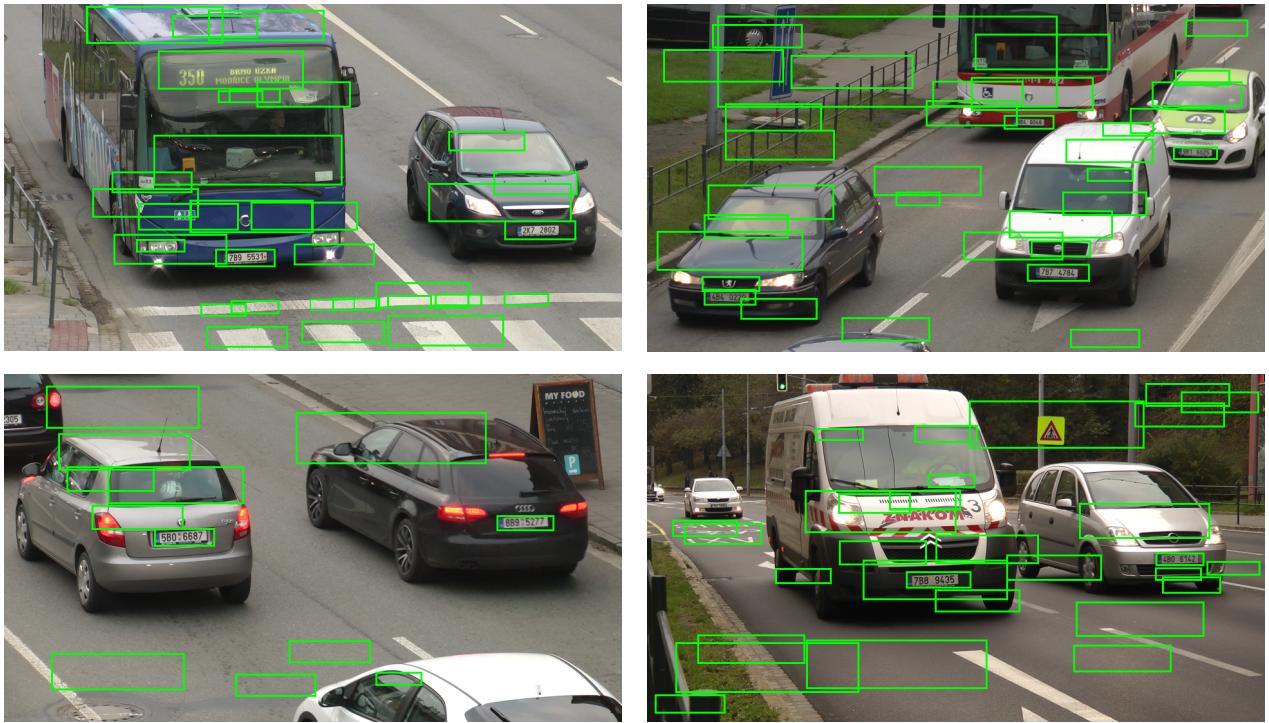
Výsledky detektoru jsou zobrazeny v tabulce 3. 238  
Výsledný detektor umí částečně najít registrační značky, 239  
které jsou z části skryté za jiným autem, ale tyto čás- 240  
tečné detekce nebyly hodnoceny. 241

Na obrázku 8 jsou zobrazeny výstupy detekce re- 242  
gistračních značek. V zelených rámečcích jsou zob- 243  
razeny plochy, které detektor považuje za registrační 244  
značky. 245

	Dataset A	Dataset B
Počet snímků	75	103
Počet RZ	96	131
Počet nalezených RZ	96	129
Počet nenalezených RZ	0	2
Úspěšnost	100 %	98.47 %

Tabulka 3. Výsledky detektoru registračních značek

Srovnání výsledků detektoru vytvořeného v rámci 246  
této práce s přístupy některých metod zmíněných v úvo- 247  
du práce je znázorněno v tabulce 4. 248



**Obrázek 8.** Ukázka výstupu detektoru registračních značek.

Metoda	Úspěšnost
Detekce použitím NN [12]	98.51 %
Kaskádový klasifikátor	98.47 %
Konstrukce CRF [7]	97.1 %
Porovnání se šablonami [1]	96.6 %
Detekce použitím MSER [2]	83.3 %

**Tabulka 4.** Srovnání výsledků detektoru s dalšími přístupy.

## 249 6. Závěr

250 Cílem této práce bylo detektovat registrační značky  
251 ve vstupním obrazu ze silniční dopravy. V kapitole  
252 2 byl představen kaskádový klasifikátor. Kapitola 3  
253 se zabývala pořízením datové sady a zpracováním  
254 vstupních snímků pro trénink detektoru registračních  
255 značek a klasifikaci znaků. Následující kapitola hovořila  
256 o natrénování detektoru registračních značek a jeho vy-  
257 hodnocení. Předposlední kapitola shrnuje dosažené  
258 výsledky.

259 Hlavním přístupem této práce bylo využití kaská-  
260 dového klasifikátoru. Jeho použitím pro detekci regis-  
261 tračních značek vznikl detektor, který dosahoval úspěš-  
262 nosti 100 % a 98.47 % na dvou testovacích datových  
263 sadách.

264 Budoucí činnost bude zaměřena na vytvoření SVM  
265 klasifikátoru pro rozpoznání znaků a následné sesta-  
266 vení registrační značky. Dále bude vytvořena aplikace,  
267 která spojí detekci registračních značek a rozpoznání  
268 znaků. Na závěr proběhne vyhodnocení úspěšnosti  
269 celé aplikace.

## Literatura

- [1] Amir Hossein Ashtari, Mohd Jan Nordin, and Seyed Mostafa Mousavi Kahaki. A new reliable approach for persian license plate detection on colour images. In *ICEEI*, pages 1–5. IEEE, 2011. 270
- [2] Wei Wang, Qiaojing Jiang, Xi Zhou, and Wenyin Wan. Car license plate detection based on MSER. In *Consumer Electronics, Communications and Networks (CECNet), 2011 International Conference on*, pages 3973–3976, April 2011. 275
- [3] Z. Musoromy, S. Ramalingam, and N. Bekooy. Edge detection comparison for license plate detection. In *Control Automation Robotics Vision (ICARCV), 2010 11th International Conference on*, pages 1133–1138, Dec 2010. 280
- [4] Z. Musoromy, F. Bensaali, S. Ramalingam, and G. Pissanidis. Comparison of real-time dsp-based edge detection techniques for license plate detection. In *Information Assurance and Security (IAS), 2010 Sixth International Conference on*, pages 323–328, Aug 2010. 285
- [5] Shyang-Lih Chang, Li-Shien Chen, Yun-Chung Chung, and Sei-Wan Chen. Automatic license plate recognition. *Intelligent Transportation Systems, IEEE Transactions on*, 5(1):42–53, March 2004. 291
- [6] Tran Duc Duan, Duong Anh Duc, and Tran Le Hong Du. Combining hough transform and contour algorithm for detecting vehicles licence 296

- 299 plates. In *International Symposium on Intelligent*  
300 *Multimedia, Video and Speech Processing*, pages  
301 747–750, 2004.
- 302 [7] Bo Li, Bin Tian, Ye Li, and Ding Wen.  
303 Component-based license plate detection using  
304 conditional random field model. *IEEE Transactions*  
305 *on Intelligent Transportation Systems*,  
306 14(4):1690–1699, 2013.
- 307 [8] Wengang Zhou, Houqiang Li, Yijuan Lu, and  
308 Qi Tian. Principal visual word discovery for auto-  
309 matic license plate detection. *IEEE Transactions*  
310 *on Image Processing*, 21(9):4269–4279, 2012.
- 311 [9] P. Cika, M. Zukal, and M. Sebela. Detection and  
312 recognition of license plates of czech vehicles.  
313 In *ElektroRevue*, volume 2, December 2011.
- 314 [10] Zhen Chao Zhang and Yuan Yan Tang. License  
315 plate recognition algorithm based on derived ker-  
316 nel. In *Wavelet Analysis and Pattern Recognition*  
317 (*ICWAPR*), 2012 International Conference on,  
318 pages 238–243, July 2012.
- 319 [11] L. Neumann. Vyhledání a rozpoznání textu v  
320 obrazech reálných scén, diplomová práce, Praha,  
321 ČVUT, 2010 [cit. 2015-03-29].
- 322 [12] J.A.G. Nijhuis, M.H. ter Brugge, K.A. Helmholt,  
323 J.P.W. Pluim, L. Spaanenburg, R.S. Venema, and  
324 M.A. Westenberg. Car license plate recognition  
325 with neural networks and fuzzy logic. In *Neural*  
326 *Networks, 1995. Proceedings., IEEE Internatio-*  
327 *nal Conference on*, volume 5, pages 2232–2236  
328 vol.5, Nov 1995.
- 329 [13] Paul Viola and Michael Jones. Rapid object de-  
330 tection using a boosted cascade of simple fea-  
331 tures. In *Accepted Conference on Computer Vision*  
332 *and Pattern Recognition*, pages 511–518, 2001.
- 333 [14] J. Matas, O. Chum, M. Urban, and T. Pajdla. Ro-  
334 bust wide baseline stereo from maximally stable  
335 extremal regions. In *In British Machine Vision*  
336 *Conference*, pages 384–393, 2002.
- 337 [15] Cascade classifier training. [http://docs.opencv.org/doc/user\\_guide/ug\\_traincascade.html](http://docs.opencv.org/doc/user_guide/ug_traincascade.html). [cit.  
338 2015-03-16].  
339  
340